

専攻科特別研究 - 2025/12/09

深層学習と知識蒸留を用いた エッジコンピュータ向け コーヒー生豆欠陥検出システムの構築



電子情報システム工学専攻 2年

天元研究室 大沼 奏太 指導教員 天元 宏

**欠点豆: 欠陥があるコーヒー生豆. コーヒーの風味を大きく低下させる.
動悸や頭痛など人体にも悪影響を与える可能性.**



図1: 正常な豆




図2: 欠点豆(欠け)



図3: 欠点豆(カビ)



図4: 欠点豆(虫食い)



**高品質なコーヒーを提供するためには、
欠点豆を確実に取り除くことが重要.**

主流の検出方法: 人の手による目視作業 豆を一粒一粒確認




図5: 選別のイメージ

時間がかかる

労力がかかる

作業者間での
判断のばらつき



近年では深層学習(AI)を活用した
自動選別の研究が進められている。

既存研究のAIモデルを現場に導入する方法は
主に2つあるが, どちらにも課題が残る.

① クラウド/サーバーを使用



- 利用コストが高い
- 常時ネット接続が必要
- 通信遅延で, リアルタイム性に欠ける

② 工場内に大型PC / 専用AI機器を設置



- 導入コストや保守コスト高い
- スペースの確保が必要
- 消費電力が多い

安価・小型なエッジコンピュータ上で動作し、
ネット接続不要でリアルタイムに、
欠陥を高精度に分類できるシステムを構築する。

エッジコンピュータとは？

- 現場(端)で処理が完結する小型コンピュータ
- Raspberry Pi 5 16GBを採用 (1万7千円)
- 安価, ネット接続が不要.
- 相対的に低性能



図6: Raspberry Pi

高性能なAIモデル: 計算量が膨大なため, 動かない or 動作が遅い
軽量なAIモデル: 速く動作するが, 低性能

知識蒸留という技術で解決可能

賢いAIモデルを教師, 軽量のAIモデルを生徒.
教師モデルの出力分布を学習目標に, 生徒モデルに知識を転移する手法.




図6: 知識蒸留の流れ

ベテランの教師が新人に経験やノウハウを伝えることで,
新人が短期間で効率よく仕事を覚えるイメージ.





図7: 提案手法の流れ

- 教師モデル:
 - 2タイプの画像認識AI (CNN系 / Transformer系) から, 取りこぼしの少なさを優先して選んだ2モデル (ResNet-50, Swin-Small) を採用.
- 生徒モデル:
 - 自作の軽量AIモデル(CNN)

正常な豆と欠点豆の2値分類の自作データセットを構築。
合計72,000枚

元データ

正常: 1,000枚
欠点: 1,000枚



データ拡張
(40度毎の回転と上下左右反転)

拡張後データ

正常: 36,000枚
欠点: 36,000枚



Swin-Smallから知識蒸留したモデルが、
知識蒸留なしのモデルの分類性能を上回ったため、本モデルを採用。

Recallとは？

- 見逃しの少なさを表す指標
- 欠点豆を見逃さないことを重視




図8: 蒸留前後のRecallの比較

表1: 蒸留前後の分類性能の比較

Model	Accuracy	Precision	Recall	F1-Score
生徒（単体）	0.928	0.944	0.910	0.927
ResNet-50 蒸留	0.907	0.926	0.885	0.905
Swin-Small 蒸留	0.945	0.948	0.943	0.945



知識蒸留後のAIモデルは, リアルタイム処理が可能




図9: 提案モデルと教師モデルのFPSの比較

FPSとは？

- 1秒間に処理できる数を表す指標
- リアルタイム処理: 30FPS ↑ が基準
- CPU使用率:
 - 96.8%使用
 - フル回転だが, 問題なし
- メモリ使用率:
 - 約 3%のみ使用
 - 非常に低い

安価・小型なエッジコンピュータ上で動作し、
ネット接続不要でリアルタイムに、
欠陥を高精度に分類できるシステムを構築することができた。

汎化性能の向上



- データ数や撮影条件を増やす
- 欠陥クラスを細分化し、欠陥の種類を判定可能に

知識蒸留手法の高度化



- 教師モデルの中間層を利用した蒸留により、さらに高精度なモデルの作成を目指す

欠陥品を弾く機構の作成



- 他分野や企業と連携し、実際の生産ラインへの導入を目指す

コーヒー以外への展開:


- 画像さえ用意できれば，他の検査にも適用可能.



水産：ホタテなどの
割れ・異物混入の検査



農業：ジャガイモなどの
傷・形状不良の検査



製造業：部品などの
欠け・傷などの外観検査

道東・北海道の水産・農業・製造の現場にも応用可能

研究背景

研究目的

提案手法

結果/考察

おわりに/今後の計画

1.研究背景

選別の自動化・エッジデバイスへの実装が必要

2.研究目的

軽量かつ高性能な欠点豆検出AIモデルの構築

3.提案手法

高性能なAIモデルと知識蒸留を用いる


4.結果/考察

軽量かつ高性能なAIモデルの作成に成功

5.おわりに/今後の計画

性能の向上, 実機作成, 他タスクに対応

畳み込みニューラルネットワーク。
画像認識で最もよく使われるモデル。



入力画像

図11: CNNのフィルター





図12: CNNの構成イメージ

- 小さなフィルタを画像上でスライドさせ, 局所的な特徴を抽出する.
- 層を重ねることで, 線や形, 模様から物体へと抽象度の高い特徴を学習
- 計算が比較的軽い

本来は自然言語処理のために提案されたモデル。
「どの部分同士が関係しているか」を学習する。

画像の場合: Vision Transformer(ViT)

- 画像を小さく分割し, 単語のように扱うことで, 画像全体の関係性を捉える
- CNNと比べて, 遠く離れた部分同士の関係を表現しやすい
- 計算量が多くなりやすい




図13: Transformer 構造図

CNNの改良版.

各ブロックで入力を出力に加える「スキップ接続」により、
非常に深いネットワークでも学習を安定させる




図14: スキップ接続




図15: ResNetモデル構成

- CNNよりも性能が良い
- 画像認識のデファクトスタンダード

- 1. 生豆を目視で検査し分類
- 2. 生豆を75粒ほど並べ, カメラ(iPhone12)を固定して撮影
- 3. 物体検出モデルYOLOを利用し, 一粒ごとに切り出し
- 4. データ拡張
- 5. 背景除去・画像サイズを均一化
- 6. データを分割 (8:1:1)

表2: データセットの割合 (計72,000枚)

	正常 (枚)	欠点 (枚)	合計 (枚)
学習用	28,800	28,800	57,600
検証用	3,600	3,600	7,200
テスト用	3,600	3,600	7,200

Accuracy (正解率):

- 全ての予測のうち, 正しく当てた割合

Precision (適合率):

- 「欠点」と予測した中で, 本当に欠点だった割合

Recall (再現率):

- 本当は欠点である豆のうち, 「欠点」と正しく検出できた割合

F1-Score:

- PrecisionとRecallの調和平均. 両者のバランスを一つの値で表した指標

帰納バイアスの違い

- ResNet教師: 生徒(CNN)と似た構造のため, 生徒が「自分でも学習できる特徴」しか教えられない可能性がある.
- Swin教師: 生徒とは異なる視点 (大域的な形状把握など) を持っている.

相補的な学習効果

- CNNが得意な「局所特徴」に, Transformerが得意な「大域的文脈」の知識が注入された
- 特に, コーヒー豆の「変形」や「大きな変色」など, 全体を見ないと判断しづらい欠陥において, Swin教師が効いたと考えられる.

- [1] Carlito Pinto, Junya Furukawa, Hidekazu Fukai, and Satoshi Tamura. Classification of green coffee bean images basec on defect types using convolutional neural network (cnn). pages 1–5, 2017.
- [2] Hidekazu Fukai, Junya Furukawa, Hiroki Katsuragawa, Carlito Pinto, and Carmelita Afonso. Classification of green coffee beans by convolutional neural network and its implementation on raspberry pi and camera module. 2018.
- [3] Nen-Fu Huang, Dong-Lin Chou, Chia-An Lee, Feng-Ping Wu, An-Chi Chuang, Yi-Hsien Chen, and YinChun Tsai. Smart agriculture: real-time classification of green coffee beans by using a convolutional neural network. IET Smart Cities, 2(4):167–172, 2020.
- [4] Ping Wang, Hsien-Wei Tseng, Tzu-Ching Chen, and Chih-Hsien Hsia. Deep convolutional neural network for coffee bean inspection. Sensors and Materials, 33:2299, 2021.