



令和 7 年度 卒業論文

深層学習と知識蒸留を用いたエッジデバイス上での
コーヒー生豆欠点豆検出システム

釧路工業高等専門学校

情報工学科

大沼 奏太

2026 年 1 月

論文要旨

コーヒー生豆の欠点豆における人手による検査は、労働集約的かつ多大な時間を要するうえ、精度のばらつきが生じやすく、スペシャルティコーヒーの安定供給を阻害する要因となっている。本論文では、Raspberry Pi 5のような低コストなエッジデバイス上での実装を想定した、高スループットかつリソース効率に優れたコーヒー生豆欠陥検出システムを提案する。ハードウェア制約下におけるモデル精度とリアルタイム推論速度の間の根本的なトレードオフを解消するため、大規模かつ高性能な教師モデルの知識を軽量の生徒 CNN へ転移させる知識蒸留 (Knowledge Distillation; KD) を採用した。

生徒モデルに対する最適な蒸留効果を明らかにするため、CNN ベースの ResNet-50 および Transformer ベースの Swin-Small という異なるアーキテクチャを持つ2つの教師モデルを体系的に比較した。独自に構築した 72,000 枚規模のデータセットを用いた評価の結果、Swin-Small 教師による蒸留が極めて有効であり、生徒 CNN の正解率 (Accuracy) をベースラインの 92.8% から 94.5% へ向上させることが示された。これは、特に表現能力 (Capacity) の低い生徒モデルへの蒸留において、ResNet 由来の高度に局所的な特徴よりも、Swin Transformer が捉える大域的かつ相補的な特徴の方が知識転移に有効であることを示唆している。

さらに、構築した生徒モデルは Raspberry Pi 5 上において優れた実行性能を達成し、メモリ使用量を約 3MB に抑えつつ、平均推論時間 9.0ms (約 110 FPS のスループット) を実現した。この処理速度は一般的な産業用ベルトコンベアの要求仕様を十分に上回るものであり、コーヒー生産プロセスにおけるリアルタイム品質管理システムとして、本提案手法が高い実用性を有していることを裏付けている。

目次

論文要旨	i
第1章 序論	1
1.1 研究背景	1
1.2 関連研究	2
1.3 研究目的	4
1.4 本論文の構成	4
第2章 関連技術	5
2.1 深層学習	5
2.2 CNN アーキテクチャ	6
2.2.1 CNN とは	6
2.2.2 ResNet とは	6
2.2.3 EfficientNet とは	7
2.3 Transformer アーキテクチャ	7
2.3.1 Transformer とは	7
2.3.2 Vision Transformer とは	7
2.3.3 Data-efficient image Transformers とは	8
2.3.4 Swin Transformer とは	8
2.4 知識蒸留	9

2.4.1	知識蒸留とは	9
2.4.2	知識蒸留の手法	9
2.5	エッジコンピューティング	9
2.5.1	エッジコンピューティングとは	9
2.5.2	Raspberry Pi とは	10
第3章	提案手法	11
3.1	システム概要	11
3.2	教師モデルの選定	12
3.3	生徒モデルの設計	12
3.4	知識蒸留の実装	14
第4章	データセット構築	15
4.1	データ収集	15
4.2	アノテーション	15
4.3	データ拡張	15
4.4	データセットの分割	15
第5章	実験	16
5.1	実験環境	16
5.2	評価指標	16
5.3	教師モデルの比較実験	16
5.4	知識蒸留の効果検証	16
5.5	エッジデバイスでの性能評価	16
第6章	考察	17
6.1	教師モデルのアーキテクチャが蒸留効果に与える影響	17

6.2 エッジデバイスでの実用性	17
6.3 本手法の限界と課題	17
第 7 章 結論	18
7.1 本研究の成果	18
7.2 今後の課題	18
7.3 展望	18
謝辞	19
参考文献	20
発表論文	22

図 目 次

3.1 提案システムの概要図	12
--------------------------	----

表 目 次

3.1 教師モデルの比較一覧	13
3.2 生徒モデルの構成	13

第1章

序論

1.1 研究背景

コーヒー生豆における「欠点豆」とは、欠け、発酵、未熟、虫食い、カビなど、焙煎後の風味や香りを著しく低下させる欠陥を有する豆を指す。これらの欠点豆が一定割合以上混入すると、焙煎後の品質が悪化し、スペシャルティコーヒーをはじめとする高品質コーヒーのブランド価値や安定供給を損なう直接的な要因となる。そのため、生産地の輸出業者や自家焙煎を行う店舗においては、焙煎の前段階で欠点豆を確実に取り除く選別工程が不可欠である。

現在、多くの現場で行われている欠点豆選別は、人手による目視検査に依存している。これは作業者がトレー上の豆を一粒ずつ観察し、欠点豆と判断したものを手作業で除去する方法であるが、労働集約的であり、かつ熟練を要する作業である。この手法には、作業者ごとの判断基準の違いや疲労により、選別精度にばらつきが生じやすく、一貫した品質管理が困難であるという課題がある [1]。さらに、多数の豆を処理するには膨大な時間的コストを要するため、コーヒー需要の増加に伴い、自動化・省力化に対するニーズは急速に高まっている。

近年, 深層学習 (Deep Learning) 技術の発展に伴い, 畳み込みニューラルネットワーク (CNN) を用いてコーヒー生豆の画像から欠点を自動検出する研究が多数報告されている [1, 2, 3]. これらの研究では, 画像分類モデルを用いることで, 熟練者の目視に近い, あるいはそれを上回る精度で良豆と欠点豆を判別できる可能性が示されている. また, 実際の生産現場や小規模ロースターでの運用を想定し, Raspberry Pi のような低コストなシングルボードコンピュータ (エッジデバイス) 上で選別システムを構築する試みも報告されている [4].

しかし, 深層学習モデルをエッジデバイス上で実運用するには, 単に分類精度が高いだけでは不十分である. エッジデバイスは計算資源 (CPU, メモリ) や電力に制約があるため, 大規模なモデルをそのまま搭載すると推論遅延が発生し, 選別ラインの速度に追従できない問題が生じる. これに対し, モデルのパラメータ数を削減しつつ性能を維持する手法として, 「知識蒸留 (Knowledge Distillation)」が知られている [5]. コーヒー豆検査の文脈においても, モデルの軽量化や効率化に関する検討はなされているものの [3], エッジデバイス上でのリアルタイム性を最優先とした場合の最適なモデル設計については十分な議論がなされていない.

特に, 知識蒸留において「どのような教師モデル (Teacher Model)」を用いるかが, 軽量の「生徒モデル (Student Model)」の性能に与える影響については未解明な点が多い. 近年, 画像認識分野では CNN に代わり Vision Transformer (ViT) が台頭しているが, コーヒー生豆の欠陥検出において, 従来の CNN と ViT のどちらを教師とすべきか, またその選択がエッジ上での推論速度やリソース消費にどう影響するかを体系的に評価した研究は見当たらない.

1.2 関連研究

伝統的な画像処理技術に代わり, CNN を用いたコーヒー生豆の欠陥分類は高い有効性が確認されている. Pinto ら [1] は, ブラジル産のコーヒー豆画像を対象に CNN を適用し, 欠けや虫食いなどの欠陥種類を高精度に分類できることを示した. また, Huang ら [2] は, スマート農業の文脈において, CNN を用いたリアルタイム分類シス

テムの構築を提案しており、選別作業の自動化が農業生産性の向上に寄与することを論じている。Wang ら [3] は、より高度な CNN アーキテクチャを用いた検査手法を提案し、欠陥検出の精度向上とモデルの効率化について検討を行っている。これらの研究は主に分類精度の向上に焦点を当てているが、実際の選別現場で求められるハードウェア制約や処理速度とのトレードオフについては、議論の余地が残されている。

自動選別システムを小規模農園や店舗へ普及させるためには、高価な GPU ワークステーションではなく、安価で小型なエッジデバイスでの動作が必須となる。Fukai ら [4] は、Raspberry Pi とカメラモジュールを組み合わせた低コストな選別システムを試作し、CNN を用いた推論を実装した。この研究により、エッジデバイスでも欠点豆の識別が可能であることが示されたが、複雑な CNN モデルをエッジ上で動作させた場合の推論遅延が課題として挙げられる。リアルタイムに流れる豆を選別するためには、数十～数百ミリ秒単位の高速な応答速度が求められるため、モデルの大幅な軽量化が必要不可欠である。

エッジデバイス向けのモデル軽量化手法として、知識蒸留 (Knowledge Distillation) が広く用いられている。これは、大規模で高性能な「教師モデル」の出力分布 (ソフトウェア) を、小規模な「生徒モデル」に学習させることで、教師の持つ知識を転移させる手法である [5]。一般的に、教師モデルと生徒モデルは同じアーキテクチャ (例: CNN 同士) であることが多いが、近年では異なるアーキテクチャ間 (例: Transformer から CNN) での蒸留効果も注目されている。しかし、コーヒー生豆のような特定のドメインデータにおいて、CNN と Transformer のどちらが教師として適しているか、またその組み合わせがエッジでの推論効率にどう寄与するかを比較検証した事例は報告されていない。本研究では、この点に着目し、エッジデバイス上での実用性を最大化する教師・生徒モデルの構成を明らかにする。

1.3 研究目的

そこで本研究では, Raspberry Pi 5 を用いたエッジコンピューティング環境において, 高速かつ高精度な欠陥検出を実現するシステムを提案する. 本論文の主な貢献は以下の通りである.

- 独自に構築した 72,000 枚規模のコーヒー生豆画像データセットを用い, CNN ベース (ResNet) および Transformer ベース (Swin Transformer) の最新モデルの性能比較を行った.
- 欠点豆の見逃し防止 (Recall) を重視した教師モデル選定を行い, 異なるアーキテクチャを持つ教師から軽量 CNN 生徒モデルへの知識蒸留を実施することで, 教師の構造が生徒の学習効果に与える影響を明らかにした.
- Raspberry Pi 5 上での実機評価を行い, 提案モデルが推論速度, CPU・メモリ使用率の観点でリアルタイム選別システムとして十分な実用性を有していることを実証した.

1.4 本論文の構成

!!!!!!最後にかく!!!!!!

第2章

関連技術

本章では、本研究で用いる主要な技術について概説する。まず深層学習の基本概念を述べ、次に CNN および Transformer ベースの画像認識モデルについて説明する。さらに、モデルの軽量化手法である知識蒸留と、本研究の実行環境であるエッジコンピューティングについて述べる。

2.1 深層学習

深層学習 (Deep Learning) とは、多層のニューラルネットワークを用いてデータから特徴を自動的に学習する機械学習手法である。従来の機械学習では人手による特徴量設計が必要であったが、深層学習ではネットワーク自体がデータから有用な特徴表現を獲得する。この特性により、画像認識、音声認識、自然言語処理など幅広い分野で高い性能を達成している。

深層学習モデルの学習では、入力データに対する出力と正解ラベルとの誤差を損失関数で評価し、誤差逆伝播法 (Backpropagation) によりネットワークのパラメータ

を更新する。学習データが十分に多く、適切なネットワーク構造を選択することで、複雑なパターンの認識が可能となる。

2.2 CNN アーキテクチャ

2.2.1 CNN とは

畳み込みニューラルネットワーク (Convolutional Neural Network, CNN) は、画像認識タスクにおいて広く用いられる深層学習モデルである。CNN は畳み込み層、プーリング層、全結合層から構成され、画像の局所的な特徴を階層的に抽出する。

畳み込み層では、小さなフィルタ (カーネル) を画像上でスライドさせながら特徴マップを生成する。プーリング層では、特徴マップの空間解像度を縮小し、位置ずれに対する頑健性を向上させる。これらの層を積み重ねることで、エッジや輪郭といった低次の特徴から、物体の形状や構造といった高次の特徴までを段階的に学習する。

2.2.2 ResNet とは

ResNet (Residual Network) は、He らによって 2015 年に提案された深層 CNN アーキテクチャである [6]。従来の深いネットワークでは、層を増やすほど学習が困難になる勾配消失問題が生じていた。

ResNet では、残差接続 (Skip Connection) と呼ばれる構造を導入し、入力をそのまま出力に加算することで、この問題を解決した。これにより、100 層を超える非常に深いネットワークの学習が可能となり、画像認識の精度が大幅に向上した。ResNet は現在でも多くの画像認識タスクにおいて基盤モデルとして広く利用されている。

2.2.3 EfficientNet とは

EfficientNet は, Tan らによって 2019 年に提案された CNN アーキテクチャである [7]. 従来のモデルでは, 精度向上のためにネットワークの深さ, 幅, 入力解像度を個別に拡張していたが, EfficientNet ではこれらを統合的にスケーリングする手法を提案した.

この複合スケーリング手法により, 少ないパラメータ数で高い精度を達成できる. EfficientNet は, 計算資源に制約のある環境においても効率的に動作するため, エッジデバイスへの適用に適したモデルとして注目されている.

2.3 Transformer アーキテクチャ

2.3.1 Transformer とは

Transformer は, Vaswani らによって 2017 年に提案されたニューラルネットワークアーキテクチャである [8]. 当初は自然言語処理のために開発されたが, 近年では画像認識分野にも応用されている.

Transformer の中核をなすのは自己注意機構 (Self-Attention) である. 自己注意機構では, 入力系列の各要素が他のすべての要素との関連性を計算し, 重要な情報に注目することができる. これにより, 入力全体の文脈を考慮した特徴表現の獲得が可能となる.

2.3.2 Vision Transformer とは

Vision Transformer (ViT) は, Dosovitskiy らによって 2020 年に提案された画像認識モデルである [9]. ViT では, 入力画像を小さなパッチに分割し, 各パッチを系列データとして Transformer に入力する.

ViT は大規模なデータセットで事前学習することにより, CNN に匹敵あるいはそれを上回る認識精度を達成する. 画像全体の大域的な関係性を捉えられる点が ViT の特長であり, 複雑なパターンの認識に有効である.

2.3.3 Data-efficient image Transformers とは

Data-efficient image Transformers(DeiT) は, Touvron らによって 2021 年に提案された ViT の改良版である [10]. ViT が高い性能を発揮するには数億枚規模の大規模データセットでの事前学習が必要であったのに対し, DeiT は ImageNet-1K のような比較的小規模なデータセットでも効率的に学習できる.

DeiT の主要な技術は, 蒸留トークンを用いた知識蒸留である. 通常のクラストークンに加えて蒸留トークンを導入し, 教師モデルの出力を直接学習する. これにより, データ効率性を大幅に向上させながら, CNN ベースの教師モデルから有用な帰納バイアスを獲得することが可能となる.

2.3.4 Swin Transformer とは

Swin Transformer は, Liu らによって 2021 年に提案された ViT の改良版である [11]. ViT では全パッチ間で注意計算を行うため計算コストが高いという課題があった.

Swin Transformer では, 画像をウィンドウに分割し, ウィンドウ内でのみ注意計算を行う. さらに, 層が深くなるにつれてウィンドウをシフトすることで, 異なる領域間の情報交換を実現する. この階層的な構造により, 計算効率を維持しながら高い認識精度を達成している.

2.4 知識蒸留

2.4.1 知識蒸留とは

知識蒸留 (Knowledge Distillation) は, Hinton らによって提案されたモデル圧縮手法である [5]. 大規模で高性能な教師モデル (Teacher Model) の知識を, 小規模な生徒モデル (Student Model) に転移させることを目的とする.

教師モデルの出力は, 単なる正解ラベルよりも豊富な情報を含んでいる. 例えば, ある画像が「猫」である確率が高く「犬」である確率もわずかにあるという出力分布は, 猫と犬の視覚的類似性を反映している. 生徒モデルはこのソフトラベルを学習することで, 教師の持つ暗黙的な知識を獲得できる.

2.4.2 知識蒸留の手法

知識蒸留では, 生徒モデルの学習時に以下の二つの損失を組み合わせて用いる.

- ハードラベル損失: 生徒の出力と正解ラベルとの誤差
- ソフトラベル損失: 生徒の出力と教師の出力との誤差

教師の出力は温度パラメータを用いてソフト化される. 温度を高くすると出力分布が滑らかになり, クラス間の関係性がより明確に伝達される. これらの損失を適切に重み付けして最小化することで, 生徒モデルは教師の性能に近づくことができる.

2.5 エッジコンピューティング

2.5.1 エッジコンピューティングとは

エッジコンピューティングとは, データの発生源に近い場所で計算処理を行う分散コンピューティングの形態である. 従来のクラウドコンピューティングでは, データをサーバに送信して処理を行うため, 通信遅延やプライバシーの問題が生じる.

エッジコンピューティングでは、センサやカメラなどのデバイス近傍で推論を実行するため、リアルタイム性の確保とデータの局所処理が可能となる。ただし、エッジデバイスは計算資源やメモリに制約があるため、軽量なモデルの設計が求められる。

2.5.2 Raspberry Pi とは

Raspberry Pi は、英国 Raspberry Pi 財団が開発した低コストのシングルボードコンピュータである。教育用途を主目的として設計されたが、その汎用性から IoT やエッジ AI 分野でも広く活用されている。

本研究で使用する Raspberry Pi 5 は、クアッドコア CPU と最大 16GB の RAM を搭載し、従来モデルより処理性能が向上している。GPU を搭載していないため、CPU 上での効率的な推論が求められるが、小型・低消費電力という特性から、実際の選別現場への導入に適している。

第3章

提案手法

本章では, 本研究で提案する手法について述べる. まず, 提案システムの概要を説明し, 次に教師モデルの選定方法について述べる. 続いて, 生徒モデルの設計方針を示し, 最後に知識蒸留の実装方法について説明する.

3.1 システム概要

本研究では, エッジデバイス上で高速かつ正確な欠陥検出を実現するために, 知識蒸留に基づく軽量画像認識モデルの構築手法を提案する. 具体的には, まず教師モデルの候補として, いくつかの最先端の CNN ベースおよび Transformer ベースの画像認識モデルを比較し, 欠点豆を見逃さないことに重点を置いた教師モデルを選定する. 次に, エッジコンピュータとして Raspberry Pi 5 を用い, その計算資源に適した軽量な生徒モデルを設計し, 教師モデルから知識蒸留を行う. 図 3.1 に提案システムの概要を示す.




図 3.1 提案システムの概要図

3.2 教師モデルの選定

本研究では、欠点豆の検出に適した教師モデルを選定するために、代表的な CNN ベースおよび Transformer ベースの画像認識モデルを比較検討する。以下の表 3.1 に、比較対象とする教師モデルの一覧を示す。これらの中から、CNN, ViT それぞれ、欠点豆の見逃しを最小限に抑えることができるモデルを選定する。

3.3 生徒モデルの設計

生徒モデルは、Raspberry Pi 5 上でのリアルタイム推論を目指し、自作した軽量 CNN モデルを採用する。構成の詳細を表 3.2 に示す。本モデルは、3 層の畳み込みブロックと分類器から構成される。各畳み込みブロックは 3×3 の畳み込みを基本とし、畳み込み層、正規化 (BN)、活性化 (ReLU)、プーリングで構成される。本モデルは、計算量を抑えつつも、欠点豆の特徴をある程度捉えることができるように設計されている。

表 3.1 教師モデルの比較一覧

アーキテクチャ	モデル名	計算量	パラメータ数
CNN	CNN(自作)	1.2 GFLOPs	2.5M
	ResNet18[6]	4.1 GFLOPs	25.6M
	ResNet50[6]	4.1 GFLOPs	25.6M
	EfficientNet-B0[7]	0.4 GFLOPs	5.3M
ViT	ViT-b16	17.6 GFLOPs	86M
	DeiT Small	4.5 GFLOPs	27.6M
	DeiT Base	4.5 GFLOPs	27.6M
	DeiT Base Distilled	4.5 GFLOPs	27.6M
	Swin Transformer Tiny[11]	4.5 GFLOPs	27.6M
	Swin Transformer Small[11]	4.5 GFLOPs	27.6M
	Swin Transformer Base[11]	4.5 GFLOPs	27.6M

表 3.2 生徒モデルの構成

Block	Component Layers	Output Size	Number of Channels
Input	-	224 x 224	3
Block1	Conv2d (3x3), BN, ReLU, MaxPool	112 x 112	8
Block2	Conv2d (3x3), BN, ReLU, MaxPool	56 x 56	16
Block3	Conv2d (3x3), BN, ReLU, MaxPool	28 x 28	32
Classifier	Global Avg Pool, Linear	1 x 1	-

3.4 知識蒸留の実装

知識蒸留は, 教師モデルの出力分布 (ソフトラベル) と正解ラベル (ハードラベル) の両方を用いる手法を採用する. 本研究では, 教師モデルと生徒モデルの出力分布間の Kullback-Leibler ダイバージェンスを蒸留損失として用いる. 全体の損失関数は以下のように定義される.

$$L = \alpha T^2 L_{KL}(p_s^\tau, p_t^\tau) + (1 - \alpha) L_{CE}(y, p_s) \quad (3.1)$$

ここで, T は温度パラメータ, α は損失の重み付け係数, L_{KL} は Kullback-Leibler ダイバージェンス, L_{CE} は正解ラベルと生徒モデルの予測のクロスエントロピー損失, p_s^τ および p_t^τ はそれぞれ生徒モデルと教師モデルの温度 T でソフト化された出力分布, y は正解ラベルを表す. 温度 T が高いほど, 教師モデルの出力分布が滑らかになり, 生徒モデルは正しいクラスだけではなく, 相対的な関係も学習できるようになる. 例えば, 豆が正常であると分類されたが, わずかに欠点豆の特徴も持っている場合, 教師モデルはその微妙な違いを反映した出力を生成することができる. 予備実験に基づき, 全ての実験において温度 $T = 2$, 重み付け係数 $\alpha = 0.5$ を採用する.

第4章

データセット構築

- 4.1 データ収集
- 4.2 アノテーション
- 4.3 データ拡張
- 4.4 データセットの分割

第5章

実験

- 5.1 実験環境
- 5.2 評価指標
- 5.3 教師モデルの比較実験
- 5.4 知識蒸留の効果検証
- 5.5 エッジデバイスでの性能評価

第6章

考察

- 6.1 教師モデルのアーキテクチャが蒸留効果に与える影響
- 6.2 エッジデバイスでの実用性
- 6.3 本手法の限界と課題

第7章

結論

7.1 本研究の成果

7.2 今後の課題

7.3 展望

謝辞

本研究は、筆者が釧路高専専攻科在学中の、大正 14 年 4 月より大正 16 年 3 月までの 2 年間にわたり行ったものである。

本研究の遂行にあたり、適切なる御指導、御助言、多大なるご援助を頂き、常に有益な討論をして頂いた、釧路高専情報工学科 KY 教授に深く感謝し御礼申し上げます。本研究を遂行にあたりご協力くださった、SS 助教ならびに SM 技官に心より感謝申し上げます。また、常に有益で適切な御討論をして頂き、貴重な御意見を頂いた釧路高専情報工学科情報通信システム研究室所属の専攻科生並びに本科生の諸氏に厚く御礼申し上げます。

本研究に関して、多くの御助言を頂いた株式会社山件マヨネーズ開発本部の皆様に深く感謝致します。また、本研究の一部は、文部省科学研究費 一般研究 (Z2)(15300010) によって行われている。

参考文献

- [1] Carlito Pinto, Junya Furukawa, Hidekazu Fukai, and Satoshi Tamura. Classification of green coffee bean images based on defect types using convolutional neural network (cnn). pages 1–5, 2017.
- [2] Nen-Fu Huang, Dong-Lin Chou, Chia-An Lee, Feng-Ping Wu, An-Chi Chuang, Yi-Hsien Chen, and YinChun Tsai. Smart agriculture: real-time classification of green coffee beans by using a convolutional neural network. *IET Smart Cities*, 2(4):167–172, 2020.
- [3] Ping Wang, Hsien-Wei Tseng, Tzu-Ching Chen, and Chih-Hsien Hsia. Deep convolutional neural network for coffee bean inspection. *Sensors and Materials*, 33:2299, 07 2021.
- [4] Hidekazu Fukai, Junya Furukawa, Hiroki Katsuragawa, Carlito Pinto, and Carmelita Afonso. Classification of green coffee beans by convolutional neural network and its implementation on raspberry pi and camera module. 2018.
- [5] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*, 2015.
- [6] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016.

- [7] Mingxing Tan and Quoc V. Le. Efficientnet: Rethinking model scaling for convolutional neural networks. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, pages 6105–6114, 2019.
- [8] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, 2017.
- [9] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations (ICLR)*, 2021.
- [10] Hugo Touvron, Matthieu Cord, Matthijs Douze, Francisco Massa, Alexandre Sablayrolles, and Hervé Jégou. Training data-efficient image transformers & distillation through attention. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, pages 10347–10357, 2021.
- [11] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 10012–10022, 2021.

発表論文

(A) 論文 (主著)

1. ○坂□男, △山凸美, 凹下凸男, 超非現実とその LSI 化について,” ○○××学会論文集, Vol.41, No.5, pp.473-480, May 2005.