



令和 7 年度 卒業論文

深層学習と知識蒸留を用いたエッジデバイス上での
コーヒー生豆欠点豆検出システム

釧路工業高等専門学校

情報工学科

大沼 奏太

2026 年 1 月

論文要旨

コーヒー生豆の欠点豆における人手による検査は、労働集約的かつ多大な時間を要するうえ、精度のばらつきが生じやすく、スペシャルティコーヒーの安定供給を阻害する要因となっている。本論文では、Raspberry Pi 5のような低コストなエッジデバイス上での実装を想定した、高スループットかつリソース効率に優れたコーヒー生豆欠陥検出システムを提案する。ハードウェア制約下におけるモデル精度とリアルタイム推論速度の間の根本的なトレードオフを解消するため、大規模かつ高性能な教師モデルの知識を軽量の生徒 CNN へ転移させる知識蒸留 (Knowledge Distillation; KD) を採用した。

生徒モデルに対する最適な蒸留効果を明らかにするため、CNN ベースの ResNet-50 および Transformer ベースの Swin-Small という異なるアーキテクチャを持つ2つの教師モデルを体系的に比較した。独自に構築した 72,000 枚規模のデータセットを用いた評価の結果、Swin-Small 教師による蒸留が極めて有効であり、生徒 CNN の正解率 (Accuracy) をベースラインの 92.8% から 94.5% へ向上させることが示された。これは、特に表現能力 (Capacity) の低い生徒モデルへの蒸留において、ResNet 由来の高度に局所的な特徴よりも、Swin Transformer が捉える大域的かつ相補的な特徴の方が知識転移に有効であることを示唆している。

さらに、構築した生徒モデルは Raspberry Pi 5 上において優れた実行性能を達成し、メモリ使用量を約 3MB に抑えつつ、平均推論時間 9.0ms (約 110 FPS のスループット) を実現した。この処理速度は一般的な産業用ベルトコンベアの要求仕様を十分に上回るものであり、コーヒー生産プロセスにおけるリアルタイム品質管理システムとして、本提案手法が高い実用性を有していることを裏付けている。

目次

論文要旨	i
第1章 序論	1
1.1 研究背景	1
1.2 関連研究	2
1.3 研究目的	3
1.4 本論文の構成	4
第2章 関連技術	5
2.1 深層学習	6
2.2 CNN アーキテクチャ	6
2.2.1 CNN とは	6
2.2.2 ResNet とは	6
2.2.3 efficientNet とは	6
2.3 Transformer アーキテクチャ	6
2.3.1 Transformer とは	6
2.3.2 Vision Transformer とは	6
2.3.3 Swin Transformer とは	6
2.4 知識蒸留	6
2.4.1 知識蒸留とは	6

2.4.2	知識蒸留の手法	6
2.5	エッジコンピューティング	6
2.5.1	エッジコンピューティングとは	6
2.5.2	Raspberry Pi とは	6
第 3 章	提案手法	7
3.1	システム概要	7
3.2	教師モデルの選定	7
3.3	生徒モデルの設計	7
3.4	知識蒸留の実装	7
第 4 章	データセット構築	8
4.1	データ収集	8
4.2	アノテーション	8
4.3	データ拡張	8
4.4	データセットの分割	8
第 5 章	実験	9
5.1	実験環境	9
5.2	評価指標	9
5.3	教師モデルの比較実験	9
5.4	知識蒸留の効果検証	9
5.5	エッジデバイスでの性能評価	9
第 6 章	考察	10
6.1	教師モデルのアーキテクチャが蒸留効果に与える影響	10
6.2	エッジデバイスでの実用性	10

6.3 本手法の限界と課題	10
第7章 結論	11
7.1 本研究の成果	11
7.2 今後の課題	11
7.3 展望	11
謝辞	12
参考文献	13
発表論文	14

图 目 次

表 目 次

第1章

序論

1.1 研究背景

コーヒー生豆における「欠点豆」とは、欠け、発酵、未熟、虫食い、カビなど、焙煎後の風味や香りを著しく低下させる欠陥を有する豆を指す。これらの欠点豆が一定割合以上混入すると、焙煎後のカップ品質が悪化し、スペシャルティコーヒーをはじめとする高品質コーヒーのブランド価値や安定供給を損なう直接的な要因となる。そのため、生産地の輸出業者や自家焙煎を行う店舗においては、焙煎の前段階で欠点豆を確実に取り除く選別工程が不可欠である。

現在、多くの現場で行われている欠点豆選別は、人手による目視検査に依存している。これは作業者がトレー上の豆を一粒ずつ観察し、欠点豆と判断したものを手作業で除去する方法であるが、労働集約的であり、かつ熟練を要する作業である。この手法には、作業者ごとの判断基準の違いや疲労により、選別精度にばらつきが生じやすく、一貫した品質管理が困難であるという課題がある [1]。さらに、多数の豆を処理するには膨大な時間的コストを要するため、コーヒー需要の増加に伴い、自動化・省力化に対するニーズは急速に高まっている。

近年, 深層学習 (Deep Learning) 技術の発展に伴い, 畳み込みニューラルネットワーク (CNN) を用いてコーヒー生豆の画像から欠点を自動検出する研究が多数報告されている [1, 3, 4]. これらの研究では, 画像分類モデルを用いることで, 熟練者の目視に近い, あるいはそれを上回る精度で良豆と欠点豆を判別できる可能性が示されている. また, 実際の生産現場や小規模ロースターでの運用を想定し, Raspberry Pi のような低コストなシングルボードコンピュータ (エッジデバイス) 上で選別システムを構築する試みも報告されている [2].

しかし, 深層学習モデルをエッジデバイス上で実運用するには, 単に分類精度が高いだけでは不十分である. エッジデバイスは計算資源 (CPU, メモリ) や電力に制約があるため, 大規模なモデルをそのまま搭載すると推論遅延が発生し, 選別ラインの速度に追従できない問題が生じる. これに対し, モデルのパラメータ数を削減しつつ性能を維持する手法として, 「知識蒸留 (Knowledge Distillation)」が知られている [Hinton et al.]. コーヒー豆検査の文脈においても, モデルの軽量化や効率化に関する検討はなされているものの [4], エッジデバイス上でのリアルタイム性を最優先とした場合の最適なモデル設計については十分な議論がなされていない.

特に, 知識蒸留において「どのような教師モデル (Teacher Model)」を用いるかが, 軽量の「生徒モデル (Student Model)」の性能に与える影響については未解明な点が多い. 近年, 画像認識分野では CNN に代わり Vision Transformer (ViT) が台頭しているが, コーヒー生豆の欠陥検出において, 従来の CNN と ViT のどちらを教師とすべきか, またその選択がエッジ上での推論速度やリソース消費にどう影響するかを体系的に評価した研究は見当たらない.

1.2 関連研究

伝統的な画像処理技術に代わり, CNN を用いたコーヒー生豆の欠陥分類は高い有効性が確認されている. Pinto ら [1] は, ブラジル産のコーヒー豆画像を対象に CNN を適用し, 欠けや虫食いなどの欠陥種類を高精度に分類できることを示した. また, Huang ら [3] は, スマート農業の文脈において, CNN を用いたリアルタイム分類シス

テムの構築を提案しており、選別作業の自動化が農業生産性の向上に寄与することを論じている。Wang ら [4] は、より高度な CNN アーキテクチャを用いた検査手法を提案し、欠陥検出の精度向上とモデルの効率化について検討を行っている。これらの研究は主に分類精度の向上に焦点を当てているが、実際の選別現場で求められるハードウェア制約や処理速度とのトレードオフについては、議論の余地が残されている。

自動選別システムを小規模農園や店舗へ普及させるためには、高価な GPU ワークステーションではなく、安価で小型なエッジデバイスでの動作が必須となる。Fukai ら [2] は、Raspberry Pi とカメラモジュールを組み合わせた低コストな選別システムを試作し、CNN を用いた推論を実装した。この研究により、エッジデバイスでも欠点豆の識別が可能であることが示されたが、複雑な CNN モデルをエッジ上で動作させた場合の推論遅延が課題として挙げられる。リアルタイムに流れる豆を選別するためには、数十～数百ミリ秒単位の高速な応答速度が求められるため、モデルの大幅な軽量化が必要不可欠である。

エッジデバイス向けのモデル軽量化手法として、知識蒸留 (Knowledge Distillation) が広く用いられている。これは、大規模で高性能な「教師モデル」の出力分布 (ソフトラベル) を、小規模な「生徒モデル」に学習させることで、教師の持つ知識を転移させる手法である [Hinton et al.]. 一般的に、教師モデルと生徒モデルは同じアーキテクチャ (例: CNN 同士) であることが多いが、近年では異なるアーキテクチャ間 (例: Transformer から CNN) での蒸留効果も注目されている。しかし、コーヒー生豆のような特定のドメインデータにおいて、CNN と Transformer のどちらが教師として適しているか、またその組み合わせがエッジでの推論効率にどう寄与するかを比較検証した事例は報告されていない。本研究では、この点に着目し、エッジデバイス上での実用性を最大化する教師・生徒モデルの構成を明らかにする。

1.3 研究目的

そこで本研究では、Raspberry Pi 5 を用いたエッジコンピューティング環境において、高速かつ高精度な欠陥検出を実現するシステムを提案する。本論文の主な貢献

は以下の通りである.

- 独自に構築した 72,000 枚規模のコーヒー生豆画像データセットを用い, CNN ベース (ResNet) および Transformer ベース (Swin Transformer) の最新モデルの性能比較を行った.
- 欠点豆の見逃し防止 (Recall) を重視した教師モデル選定を行い, 異なるアーキテクチャを持つ教師から軽量 CNN 生徒モデルへの知識蒸留を実施することで, 教師の構造が生徒の学習効果に与える影響を明らかにした.
- Raspberry Pi 5 上での実機評価を行い, 提案モデルが推論速度, CPU・メモリ使用率の観点でリアルタイム選別システムとして十分な実用性を有していることを実証した.

1.4 本論文の構成

!!!!最後にかく!!!!!!

第2章

関連技術

2.1 深層学習

2.2 CNN アーキテクチャ

2.2.1 CNN とは

2.2.2 ResNet とは

2.2.3 efficientNet とは

2.3 Transformer アーキテクチャ

2.3.1 Transformer とは

2.3.2 Vision Transformer とは

2.3.3 Swin Transformer とは

2.4 知識蒸留

2.4.1 知識蒸留とは

2.4.2 知識蒸留の手法

2.5 エッジコンピューティング

2.5.1 エッジコンピューティングとは

2.5.2 Raspberry Pi とは

第3章

提案手法

- 3.1 システム概要
- 3.2 教師モデルの選定
- 3.3 生徒モデルの設計
- 3.4 知識蒸留の実装

第4章

データセット構築

- 4.1 データ収集
- 4.2 アノテーション
- 4.3 データ拡張
- 4.4 データセットの分割

第5章

実験

- 5.1 実験環境
- 5.2 評価指標
- 5.3 教師モデルの比較実験
- 5.4 知識蒸留の効果検証
- 5.5 エッジデバイスでの性能評価

第6章

考察

- 6.1 教師モデルのアーキテクチャが蒸留効果に与える影響
- 6.2 エッジデバイスでの実用性
- 6.3 本手法の限界と課題

第7章

結論

7.1 本研究の成果

7.2 今後の課題

7.3 展望

謝辞

本研究は、筆者が釧路高専専攻科在学中の、大正 14 年 4 月より大正 16 年 3 月までの 2 年間にわたり行ったものである。

本研究の遂行にあたり、適切なる御指導、御助言、多大なるご援助を頂き、常に有益な討論をして頂いた、釧路高専情報工学科 KY 教授に深く感謝し御礼申し上げます。本研究を遂行にあたりご協力くださった、SS 助教ならびに SM 技官に心より感謝申し上げます。また、常に有益で適切な御討論をして頂き、貴重な御意見を頂いた釧路高専情報工学科情報通信システム研究室所属の専攻科生並びに本科生の諸氏に厚く御礼申し上げます。

本研究に関して、多くの御助言を頂いた株式会社山件マヨネーズ開発本部の皆様に深く感謝致します。また、本研究の一部は、文部省科学研究費 一般研究 (Z2)(15300010) によって行われている。

参考文献

- [1] 古井 貞熙, “音響・音声工学”, 近代科学社, 1992.
- [2] 中川 聖一, “確率モデルによる音声認識”, コロナ社, 1988.

発表論文

(A) 論文 (主著)

1. ○坂□男, △山凸美, 凹下凸男, 超非現実とその LSI 化について,” ○○××学会論文集, Vol.41, No.5, pp.473-480, May 2005.