

深層学習と知識蒸留を用いた エッジデバイス上でのコーヒー生豆欠点豆検出システム

釧路高専専攻科 電子情報システム工学専攻 天元研究室(天元 宏) 研究室 大沼 奏太

Defect Detection System for Green Coffee Beans on Edge Devices Using Deep Learning and Knowledge Distillation

Sota Onuma

Advanced Course of Electronic and Information Systems Engineering
National Institute of Technology, Kushiro College

Abstract

Manual inspection of defective green coffee beans, known as “hand picking,” is time-consuming and inconsistent. This study proposes an automated defect detection system by distilling knowledge from a high-capacity Vision Transformer (ViT) into a lightweight model suitable for edge devices such as Raspberry Pi. We are currently collecting and augmenting a large dataset of normal and defective beans to improve model generalization. Our goal is to achieve low false positive rates, meet commercial grading standards, and deliver a cost-effective, high-accuracy solution for coffee producers and retailers.

Keywords Defect Detection, Knowledge Distillation, Edge Computing, Coffee Beans

1. はじめに

コーヒー生豆の欠点豆とは、欠け・発酵・未熟・虫食いなどといった、コーヒーの風味に影響を及ぼすものである。現在主流の選別作業は人手で欠点豆を取り除くもので、生産地や自家焙煎を行う店で行われている。この手動による選別は労働集約的で時間がかかり、異なる人間による判断の一貫性や正確性の欠如という問題を抱えている [1]。そこで AI を使った自動検査・選別の研究がされてきた。コーヒー生豆の欠陥検査に関しては、多くの研究が報告されている。複数種類の欠点豆を識別する CNN 分類モデルを構築した研究 [1] や、Raspberry Pi 上に CNN モデルを実装して、複数種類の欠点豆を識別する研究 [2] も報告されている。Nen-Fu Huang ら [3] は CNN を用いて良豆と欠点豆の 2 値分類を行い、94.63% の正解率と偽陽性率 4.41% を得ている。この研究ではデスクトップ PC での推論を前提としているため、エッジコンピュータへの実装は考慮されていない。Ping Wang ら [4] は、このアプローチをさらに発展させ、知識蒸留を活用し、大規模 CNN モデルを軽量モデルへ圧縮した。さらに、モデルの判断根拠を可視化することにより、軽量かつ判断根拠を説明可能なコーヒー生豆欠陥検出システムを提案した。このアプローチは正解率 91% を維持しつつ、モデルサイズとメモリ消費量を大幅に削減し

た。Ping Wang ら [4] の研究は、CNN をベースとしたモデルで知識蒸留の有効性を示したが、近年、画像認識の分野では Vision Transformer (ViT) をはじめとする Transformer ベースのモデルが CNN を上回る性能を示す事例が報告されている。しかし、コーヒー生豆欠陥検出という特定のタスクにおいて、どのアーキテクチャが最適な教師モデルとなり得るのか、また、それらを知識蒸留した際に、軽量な生徒モデルのアーキテクチャの違いによって性能にどのような差異が生まれるのかは、未だ明らかにされていない。さらに、CPU 使用率や推論速度といったエッジコンピュータ上での実用度が十分に検討されていない。

2. 提案手法について

本研究では、教師モデルとして高性能で大きなモデルを採用し、その知識を知識蒸留によって、Raspberry Pi などのエッジコンピュータで動くようなモデルで欠点豆を検出する。本研究のシステム構成図を以下の図 1 に示す。

知識蒸留とは、学習モデルの予測結果を学習目標として、他のモデルを学習させる手法である。小さなモデルが大きな学習データで学習された大きなモデルと同様の判断をすることが可能になる。本研究では、大きなモデルから得た確率分布とそれに使われた画像を教師データとして、小さなモデルで学習する。今

回対象とした欠点豆は、欠け豆や奇形の豆、カビなどの明らかにわかるものを使用した。




図 1: 本研究のシステム構成図

3. これまでの進捗と現在の状況

去年の研究では、自らデータセットを作成し、それを用いて機械学習モデルを学習させることに成功した。このプロセスを通じて、データ収集や学習パイプラインの構築といった基礎的なスキルを習得した。

しかし、研究を進める中で、モデルが過学習する傾向があり、データセットのノイズや偏りが精度低下の要因となっていることが明らかになった。また、データ量が不十分であり、モデルが多様なパターンを学習するには至らなかった。

これらの課題を踏まえ、今年はデータの質と量の向上に取り組むとともに、知識蒸留を利用したモデルの構築を目指している。

まず、知識蒸留の理論と実装方法を学習し、昨年度の研究で判明したデータの不足を補うため、一般的な公開データセットである CIFAR-10 を用いて実験を行った。特に、Vision Transformer (ViT) の論文 (Dosovitskiy et al., 2021) における「十分なデータセットがなければモデルが一般化しない」という主張を検証し、知識蒸留の効果を評価した。表 1 に示すように、知識蒸留を行った場合でも精度は 56% 程度に留まり、ViT が小規模データセットに対して有効ではないことが明らかになった。

表 1: CIFAR-10 に対する ViT モデルで知識蒸留した際の精度比較

モデル	精度 (%)
教師モデル	56.76
生徒モデル(蒸留なし)	50.84
生徒モデル(蒸留あり)	52.50

さらに、昨年度のデータセットの質と量を改善するため、コーヒー豆の分類において、明

らかに欠点豆と判断できるものを対象に分類を行った。具体的には、良い豆 1000 個と欠点豆 1000 個を手動で収集し、現在、このデータをもとに豆の画像を撮影している段階である。撮影の効率化を図るため、YOLO を活用した自動化も進めている。

また、データセットの量を増やすため、画像を可能な限りクロップして対象物を明確にし、反転や回転といったデータ拡張手法を用いて 1 枚の画像から複数の画像を生成する。これにより、元の 2,000 枚の画像データを 72,000 枚に増加させることを目指している。

4. 今後の方針と計画

今後は、データセットが完成次第、学習およびエッジコンピュータ上での実行を行う。その際、以下の研究課題を検討する。

(RQ1) 先行研究モデルと蒸留有りモデルで、精度と FPR、推論速度に差はあるか?

先行研究の CNN モデル [1] と知識蒸留モデルを比較し、精度や偽陽性率 FPR、スループットを評価する。蒸留により推論速度が向上し、精度が維持されることを期待する。期待通りの性能が得られない場合、モデルの調整や別の手法を検討する。

(RQ2) CNN ベースと ViT ベースの教師モデル、どちらから蒸留した方が効果が大きいのか?

異なる教師モデル (CNN/ViT) からの蒸留による精度と偽陽性率 FPR に対する影響を検証する。小規模データセットでは CNN が有利と考えられるが、大規模事前学習した ViT の有効性も検討する。

(RQ3) 得られた最終モデルが、実際にエッジコンピュータ上で必要な性能基準を満たすか?

最終モデルがエッジ環境で実用可能な性能基準を満たすかを検証する。特に、偽陽性率 FPR、スループット、使用メモリ量を評価し、FPR の基準にはブラジルのコーヒー豆グレードを採用する。

参考文献

- [1] Nen-Fu Huang, Dong-Lin Chou, Chia-An Lee, Feng-Ping Wu, An-Chi Chuang, Yi-Hsien Chen, and Yin-Chun Tsai. Smart agriculture: real-time classification of green coffee beans by using a convolutional neural network. *IET Smart Cities*, 2(4):167–172, 2020.