

Vision-Transformerとエッジコンピュータを用いた コーヒー生豆の欠陥検出

釧路高専専攻科 電子情報システム工学専攻 天元研究室(天元 宏) 研究室 大沼 奏太

Defect detection in green coffee beans using Vision-Transformer and edge computer.

Sota Onuma

Advanced Course of Electronic and Information Systems Engineering
National Institute of Technology, Kushiro College

Abstract

Manual inspection of defective green coffee beans, known as “hand picking,” is time-consuming and inconsistent. This study proposes an automated defect detection system by distilling knowledge from a high-capacity Vision Transformer (ViT) into a lightweight model suitable for edge devices such as Raspberry Pi. We are currently collecting and augmenting a large dataset of normal and defective beans to improve model generalization. Our goal is to achieve low false positive rates, meet commercial grading standards, and deliver a cost-effective, high-accuracy solution for coffee producers and retailers.

Keywords Defect Detection, Knowledge Distillation, Edge Computing, Coffee Beans

1. はじめに

コーヒー生豆の欠点豆とは、欠け・発酵・未熟・虫食いなどといった、コーヒーの風味に影響を及ぼすものである。その欠点豆を取り除くための方法は様々ある。その中のハンドピックという作業は、人手で欠点豆を取り除くもので、生産地や自家焙煎を行う店で主に行われている。この手動による選別は労働集約的で時間がかかり、異なる人間による判断の一貫性や正確性の欠如という問題を抱えている [1]。そこでAIを使った自動検査・選別の研究がされてきた。

コーヒー生豆の欠陥検査に関しては、多くの研究が報告されている。中でも、Nen-Fu Huang ら [2] は CNN を用いて良豆と欠点豆の2値分類を行い、94.63%の精度と偽陽性率 0.0441 を得ている。偽陽性率が 0.0441 というのは、ブラジルのコーヒーの No.2 から No.6 まである品質基準に照らすと、輸出最低グレードであり、実用に向けてまだ改善する必要がある。さらにこの研究ではデスクトップ pc での推論を前提としているため、エッジコンピュータへの実装は考慮されていない。また、東ティモールのコーヒー豆選別を対象として、複数種類の欠陥(黒豆、酸味豆、破損豆など)を識別する CNN 分類モデルを構築した研究 [1] や、Raspberry Pi 上に CNN モデルを実装して、同じく複数種類の欠

点豆を識別する研究 [3] も報告されている。これらは多クラス分類を行う点や実装方法が異なるため、本研究とは直接的に数値比較が難しいが、エッジコンピュータ上での推論や発展途上国のコーヒー生産支援という点で参考にできる。

本研究では、エッジコンピュータ上での実装時の評価指標として偽陽性率や精度を重視するため、Nen-Fu Huang ら [2] の検証結果を基準として議論する。以上の先行研究から、(1)FPR・精度の向上、(2)エッジコンピュータ上での実装による小コスト化をする必要がある。本研究では、高精度で偽陽性率が低いかつエッジコンピュータで動作可能なモデルを作成することを目的とする。

2. 提案手法について

本研究では、教師モデルとして高性能で大きなモデルを採用し、その知識を知識蒸留によって、Raspberry Pi などのエッジコンピュータで動くようなモデルで欠点豆を検出する。本研究のシステム構成図を以下の図 1 に示す。

知識蒸留とは、学習モデルの予測結果を学習目標として、他のモデルを学習させる手法である。小さなモデルが大きな学習データで学習された大きなモデルと同様の判断をすることが可能になる。本研究では、大きなモデルから得た確率分布とそれに使われた画像を教

師データとして、小さなモデルで学習する。今回対象とした欠点豆は、欠け豆や奇形の豆、カビなどの明らかにわかるものを使用した。




図 1: 本研究のシステム構成図

3. これまでの進捗と現在の状況

去年の研究では、自らデータセットを作成し、それを用いて機械学習モデルを学習させることに成功した。このプロセスを通じて、自分でデータを収集し、学習パイプラインを構築する基礎的なスキルを習得した。しかし、研究を進める中で以下のような課題が浮き彫りになった。

- モデルが過学習する傾向が見られた。データセットが不十分であると考えられる。
- データセットの質が十分ではなく、ノイズや偏りが精度低下の原因となっていた。
- データセットの量も不十分であり、モデルが多様なパターンを学習するには至らなかった。

これらの課題を踏まえ、今年はデータの質と量を向上させる取り組みに加え、知識蒸留を利用したモデルの構築を目指している。

今年度の研究では、まず知識蒸留の理論と実装方法について学習を行った。自ら収集したデータセットでは学習データの量と質が十分ではないと昨年度の研究で明らかになったため、一般的な公開データセットである

CIFAR-10 を用いて、知識蒸留の効果と Vision Transformer (ViT) の論文における「十分なデータセットがなければモデルが一般化しない」という主張 [4] を検証する実験を行った。表 1 は、CIFAR-10 に対する ViT モデルで知識蒸留した際の精度比較をしたものである。知識蒸留を行った場合でも精度は 56% 程度に留まったことから、ViT は小規模データセットに対して有効ではないということが明らかになった。

表 1: CIFAR-10 に対する ViT モデルで知識蒸留した際の精度比較

モデル	精度 (%)
教師モデル	56.76
生徒モデル (蒸留なし)	50.84
生徒モデル (蒸留あり)	52.50

昨年度のデータセットの質と量を改善するために、コーヒー豆の分類において明らかに欠点豆と判断できるものを対象に分類を行った。具体的には、良い豆 1000 個と欠点豆 1000 個を手動で収集した。現在、このデータをもとに豆の画像を撮影している段階であり、撮影を効率化するために YOLO を活用して自動化を進めている。さらに、データセットの量を増加させるために画像処理技術を活用し、以下のようなデータ拡張を計画している。

- 画像を可能な限りクロップすることで、対象物をより明確にする。
- 反転や回転といったデータ拡張手法を用いて、1 枚の画像から複数の画像を生成する。

これにより、元の 2,000 枚の画像データを 72,000 枚に増加させることを目指している。

4. 今後の方針と計画

今後は、データセットが完成次第、学習およびエッジコンピュータ上での実行をする方針である。その際に、以下のような研究課題に答える。

(RQ1) 先行研究モデルと蒸留有りモデルで、精度と FPR、推論速度に差はあるか?

まず、先行研究 [2] の CNN モデルと作成した知識蒸留済みモデルを比較する。性能を測定するため、テスト用データセットに対する精度、偽陽性率 FPR、スループット (推論速度) を用いる。蒸留ありモデルでは、精度が先行研究モデルと同程度でスループットが向上するのではないかと仮説する。ここで、「蒸留による性能向上」が確認できれば「蒸留は有効だ」と言えるが、もし想定よりも効果が出なければ調整や別のモデルを検討する。

(RQ2) CNN ベースと ViT ベースの教師モデル、どちらから蒸留した方が効果が大きいのか?

RQ2 では、どの教師モデルを採用すると性能が向上するかを検証する。それぞれの蒸留済みモデルに対して、精度と偽陽性率 FPR の指標を測定する。小規模データセットにおいては、CNN ベースの教師モデルが学習に適し

ていると考えられる。一方で、大規模事前学習した ViT を教師とする場合でも、同等の性能が得られる可能性がある。

(RQ3) 得られた最終モデルが、実際にエッジコンピュータ上で必要な性能基準を満たすか?

RQ3 では、RQ2 で得られた最終的なモデルが、エッジコンピュータ上で実際の性能基準を満たすかどうか検証する。具体的には、評価指標として偽陽性率 FPR、スループット、使用メモリ量を満たすか検証する。偽陽性率 FPR の基準としてブラジルのグレード基準を採用する。これは、300g のコーヒー豆の中にどのくらい欠点豆が含まれているかという基準である。グレードは、No.6 から No.2 まであり、数が小さくなっていくにつれて高品質であることを示す。本研究では、300g 中に含まれるコーヒー豆の数を、豆一つの重さを 0.15g とし、2000 個とし、ブラジルのグレードから偽陽性率を算出した。その結果を表 2 に示す。先行研究のモデル [2] の偽陽性率 FPR は 0.0441 であり、ブラジルの輸出最低グレード No.6 を下回る。よって、本研究では No.6 を上回る偽陽性率 FPR を目指す。

表 2: 欠点豆グレードと FPR の対応表

グレード	300g 中の欠点豆数 (個)	必要最低 FPR
No.2	0-4	0.002
No.3	5-8	0.004
No.4	9-26	0.013
No.5	27-46	0.023
No.6	47-86	0.043

参考文献

- [1] Carlito Pinto, Junya Furukawa, Hidekazu Fukai, and Satoshi Tamura. Classification of green coffee bean images basec on defect types using convolutional neural network (cnn). pages 1–5, 2017.
- [2] Nen-Fu Huang, Dong-Lin Chou, Chia-An Lee, Feng-Ping Wu, An-Chi Chuang, Yi-Hsien Chen, and Yin-Chun Tsai. Smart agriculture: real-time classification of green coffee beans by using a convolutional neural network. *IET Smart Cities*, 2(4):167–172, 2020.
- [3] Hidekazu Fukai, Junya Furukawa, Hiroki Katsuragawa, Carlito Pinto, and Carmelita Afonso. Classification of green coffee beans by convolutional neural network and its implementation on raspberry pi and camera module. 2018.
- [4] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. 2021.